# Métodos Cuantitativos II

## *Modelos no estacionarios II: componente estacional*

Alejandro Mosiño - *Universidad de Guanajuato*

v. 2026.03.20

PDF

# Introducción

# Estacionariedad (1/4)

Recordemos que para que una serie de tiempo, $y_t$ , sea estacionaria (en covarianza), es necesario que:

- Su media y varianza sean constantes. Esto es, para todo $t \in \mathbb{Z}$:

$$\mathbb{E}(y_t) = \mu;$$
$$\mathbb{V}ar(y_t) = \gamma_0 < \infty$$

- Su función de autocovarianza dependa solo del desfase $h$ y no del tiempo $t$:

$$\gamma(t, \tau) = \gamma(h);\ h = |t - \tau| \ \in \mathbb{Z}$$

# Estacionariedad (2/4)

Las siguientes series de tiempo podrían ser estacionarias:

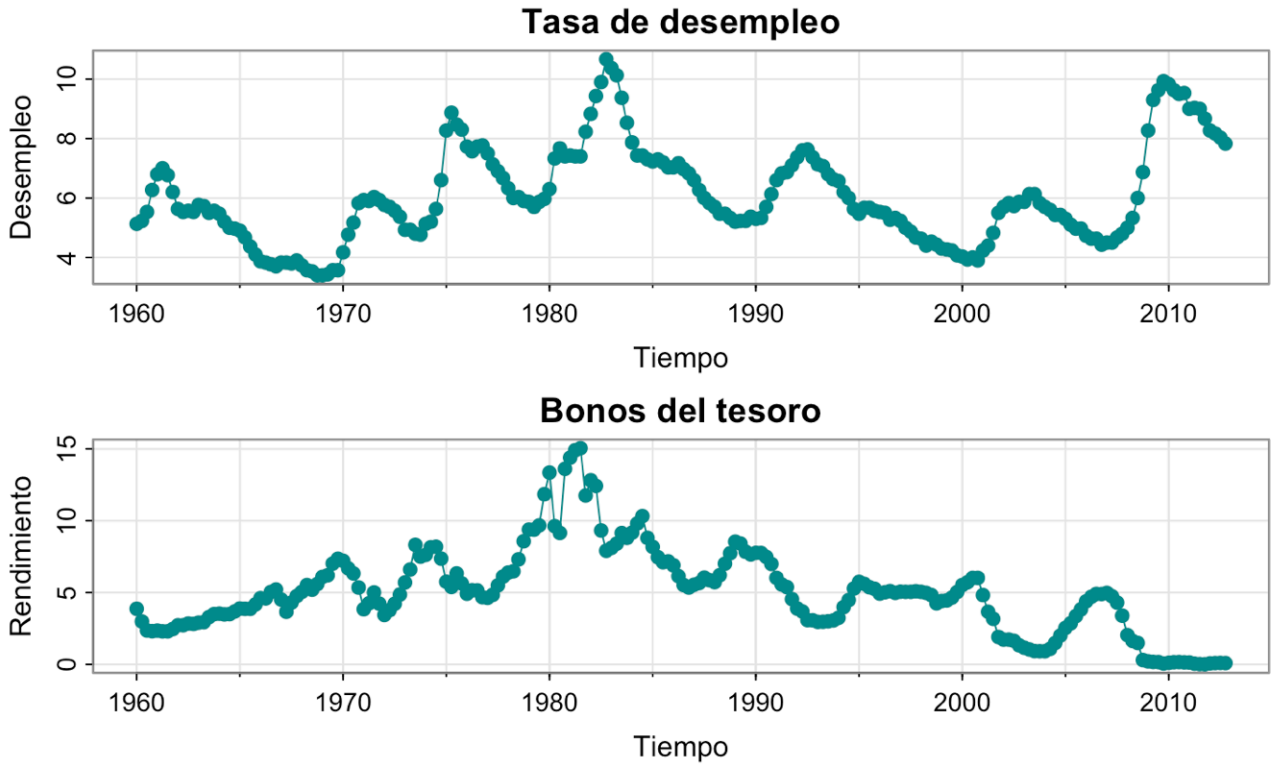

# Estacionariedad (3/4)

¿Qué pasa si las series de tiempo presentan un **patrón estacional**? Por ejemplo:

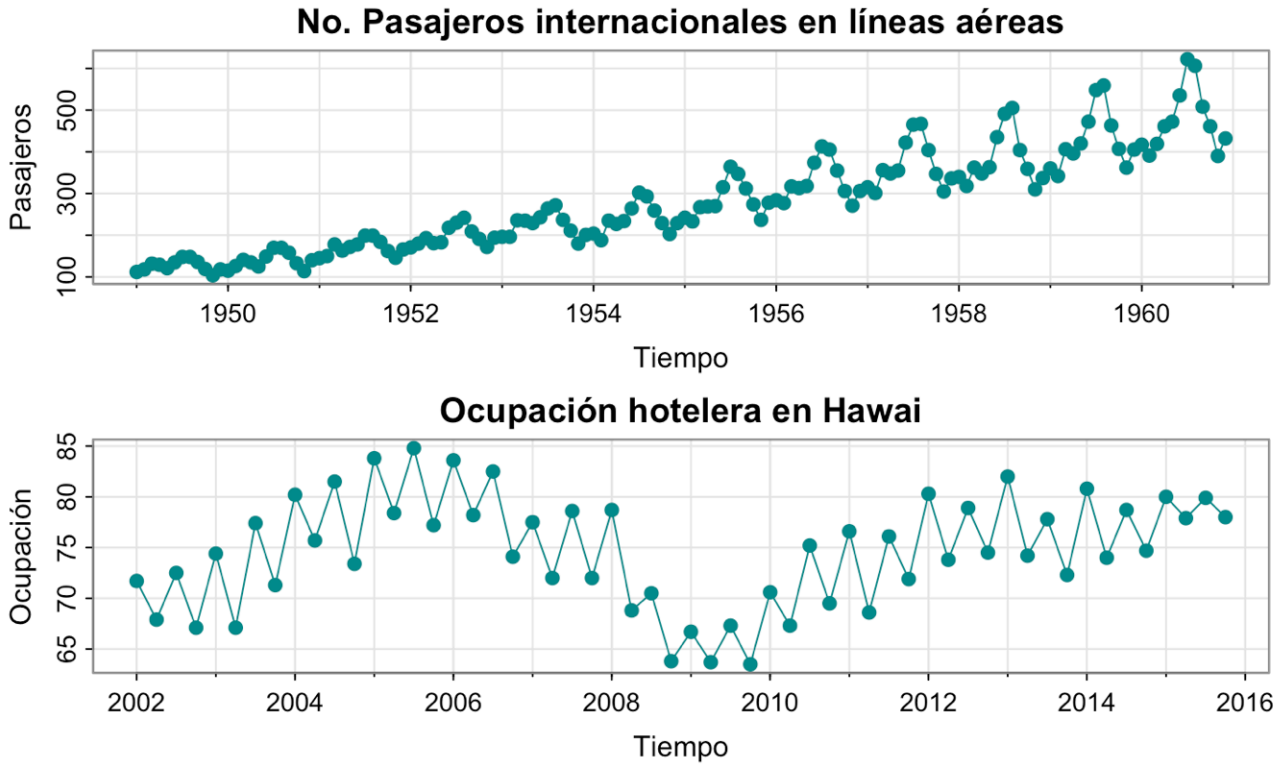

# Estacionariedad (4/4)

*Los modelos con patrón estacional violan directamente la condición de estacionariedad*, esto es debido a que:

$$\mathbb{E}(y_t) = \mu_s$$

donde $s$ indica la estación (mes, trimestre, etc.)

# Incorporación del componente estacional en el modelo (1/3)

El componente de la serie de tiempo que representa la variabilidad en los datos debida a influencias de las estaciones, se llama **componente estacional**. Existen dos formas diferentes para incorporar este componente en el modelo:

- **Componente determinista**. Incorporamos *explícitamente* en el modelo un patrón estacional.
- **Componente estocástico**. El patrón estacional proviene de una *raíz unitaria estacional*.

# Incorporación del componente estacional en el modelo (2/3)

Componente determinista vs. Componente estocástico

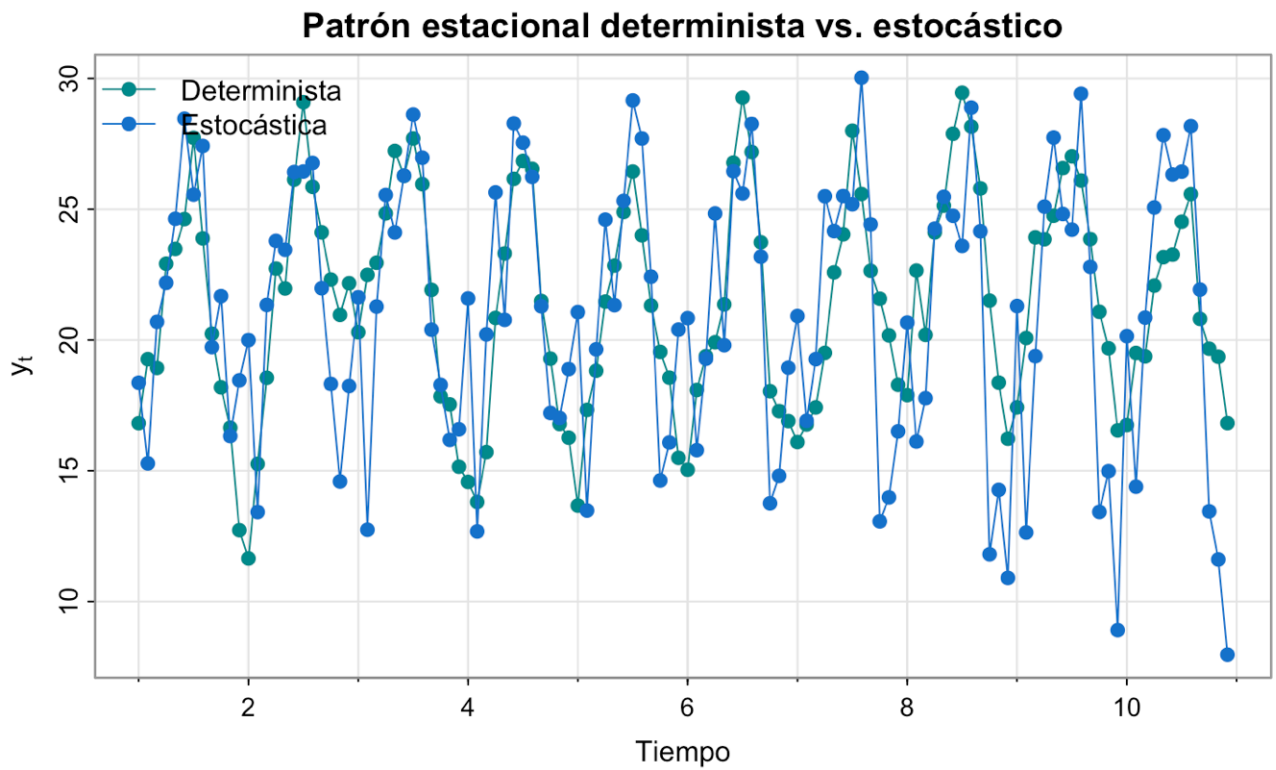

# Incorporación del componente estacional en el modelo (3/3)

Aunque los dos tipos de componente estacional son visualmente parecidos, las implicaciones teóricas y prácticas son diferentes:

- En un modelo con componente estacional determinista, los shocks tienen *efectos transitorios*. En un modelo con componente estacional estocástico, los shocks tienen *efectos persistentes*.

- El procedimiento para *remover* el componente estacional y hacer la serie estacionaria es distinto para cada caso.

# Componente estacional determinista

# Componente estacional determinista

Las siguientes series muestran un patrón estacional muy claro:

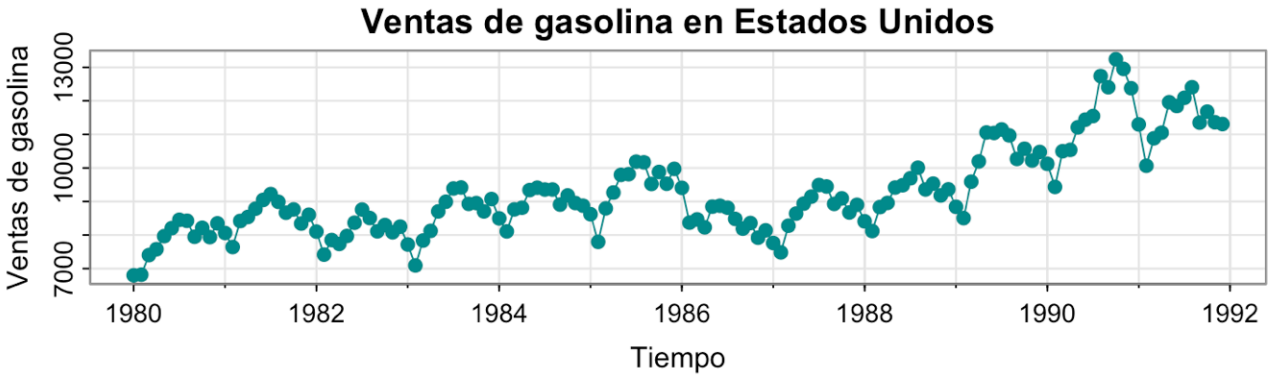


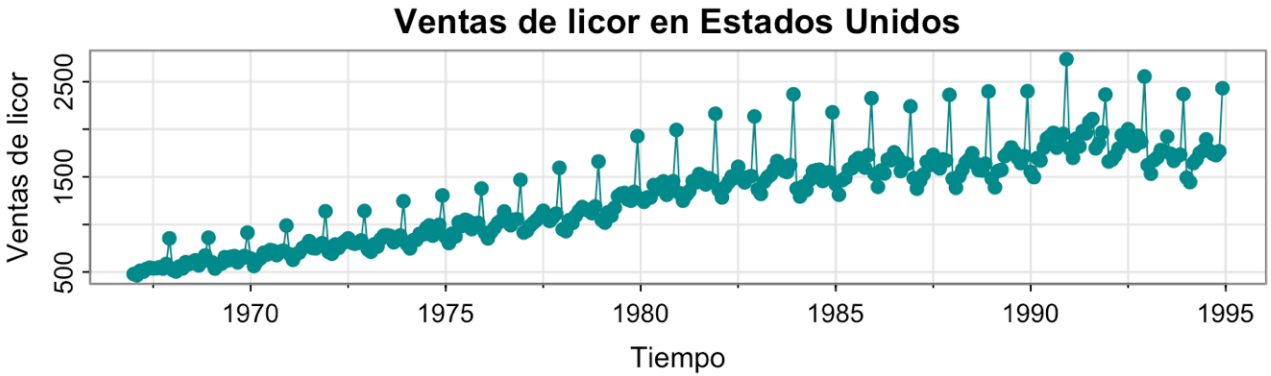

# Modelo estacional puro (1/2)

Para incorporar el componente estacional determinista en el modelo, supongamos que $s$ es el número de estaciones en un año. Debemos construir un conjunto de $s$ **variables dummy estacionales**. Por ejemplo, si $s = 4$ (datos trimestrales):

$$
\begin{aligned}
D_1 &= \begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & \dots \end{pmatrix} \\
D_2 &= \begin{pmatrix} 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & \dots \end{pmatrix} \\
D_3 &= \begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & \dots \end{pmatrix} \\
D_4 &= \begin{pmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & \dots \end{pmatrix}
\end{aligned}
$$

# Modelo estacional puro (2/3)

El **modelo estacional puro** es:

$$y_t = \sum_{i=1}^{s} \gamma_i D_{it} + \varepsilon_t$$

Básicamente, tenemos un modelo en el que el intercepto es diferente en cada estación. Los coeficientes $\gamma_i$ se conocen como **factores estacionales**.

*Nota*. Como siempre, debemos tener cuidado de no caer en la *trampa de las dummies*.

# Modelo estacional con tendencia (1/2)

También podemos incluir una *tendencia determinista* en un modelo estacional. Por ejemplo, si aumentamos el modelo estacional puro con una tendencia lineal tenemos:

$$y_t = \beta_1 t + \sum_{i=1}^{s} \gamma_i D_{it} + \varepsilon_t$$

También es posible tener modelos más complejos:

$$y_t = \beta_1 t + \sum_{i=1}^{s} \gamma_i D_{it} + \sum_{i=1}^{v_1} \delta_i^{HD} HDV_{it} + \sum_{i=1}^{v_2} \delta_i^{TD} TDV_{it} + \varepsilon_t$$

donde $HDV$ representa periodos de fiesta relevantes, y $TDV$ son periodos de comercio relevantes. Estas también son variables dummy.

*Los estimadores de los coeficientes de todos estos modelos pueden obtenerse por MCO.*

# Modelo estacional con tendencia (2/2)

Por ejemplo, considera las ventas de gasolina en Estados Unidos (en dólares):

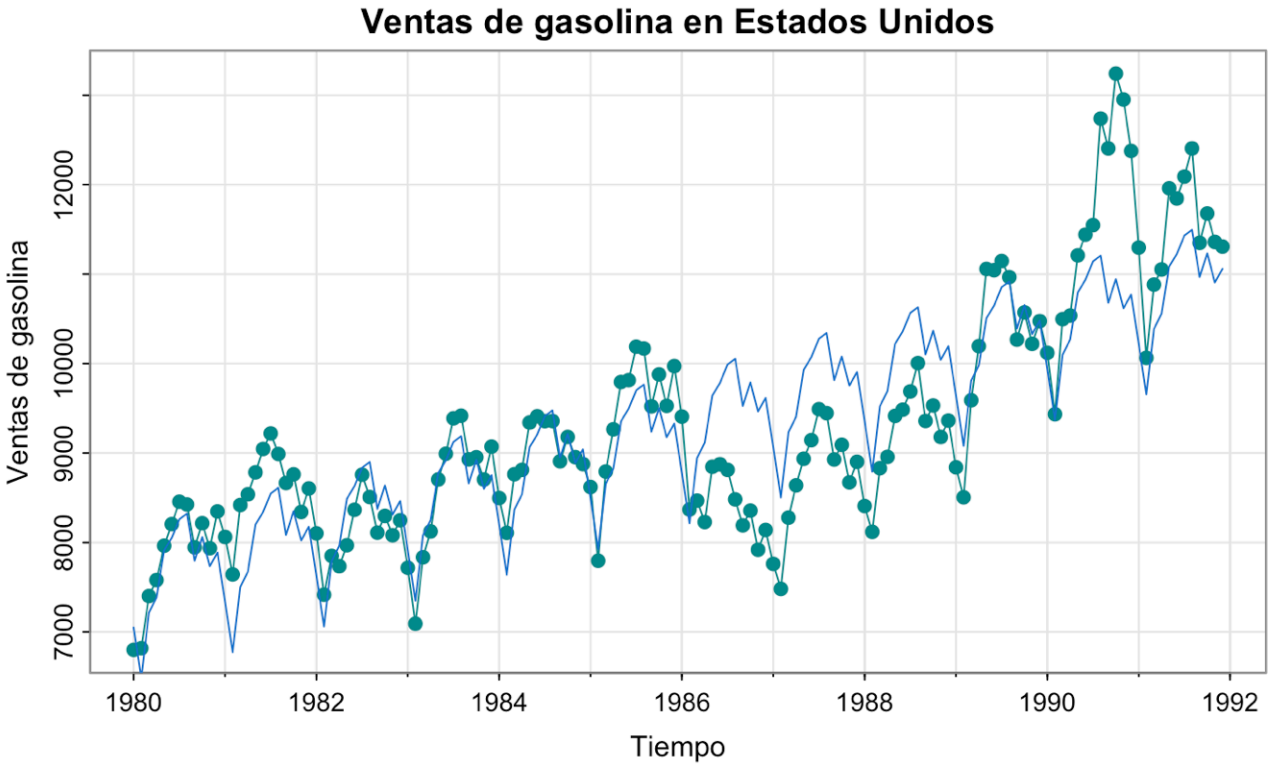

# Ejercicio (1/4)

### Ejercicio

Considera el modelo:

$$y_t = \sum_{i=1}^{s} \gamma_i D_{it} + \varepsilon_t$$

Muestra que $y_t$ no es estacionario.

# Ejercicio (2/4)

**Nota**

Considera el modelo:

$$y_t = \sum_{i=1}^{s} \gamma_i D_{it} + \varepsilon_t$$

Una forma de hacer que este modelo sea estacionario, consiste en calcular:

$$\begin{aligned} y_t^* &= y_t - \sum_{i=1}^{s} \gamma_i D_{it} \\ &= \varepsilon_t \end{aligned}$$

Esta transformación puede hacerse operacional reemplazando los $\gamma_i$ por sus estimadores de MCO.

# Ejercicio (3/4)

### Ejercicio

A diferencia de los modelos con tendencia, aplicar diferencias a un modelo con componente estacional no hace que la serie de tiempo sea estacionaria. Por ejemplo, considera el modelo:

$$y_t = \sum_{i=1}^{s} \gamma_i D_{it} + \varepsilon_t$$

Muestra que $\Delta y_t$ no es estacionario.

# Ejercicio (4/4)

### Ejercicio

Considera el modelo con datos trimestrales ($s = 4$):

$$y_t = \sum_{i=1}^{4} \gamma_i D_{it} + \varepsilon_t$$

Muestra que $\Delta^4 y_t = y_t - y_{t-4}$ es estacionario. Este es un ejemplo de modelos **ARIMA estacionales**, también conocidos como modelos **SARIMA**.

**Nota.** Los modelos SARIMA nos permiten tratar la **estacionalidad estocástica**, la cual ocurre cuando *el patrón estacional no es constante sino que evoluciona en el tiempo*.

# Ejemplo

## Ejemplo

Las técnicas habituales para analizar y pronosticar series de tiempo, aplican también para los modelos con componente estacional (ver modelos ARMA). Por ejemplo, para las ventas de gasolina en Estados Unidos (en dólares) tenemos:

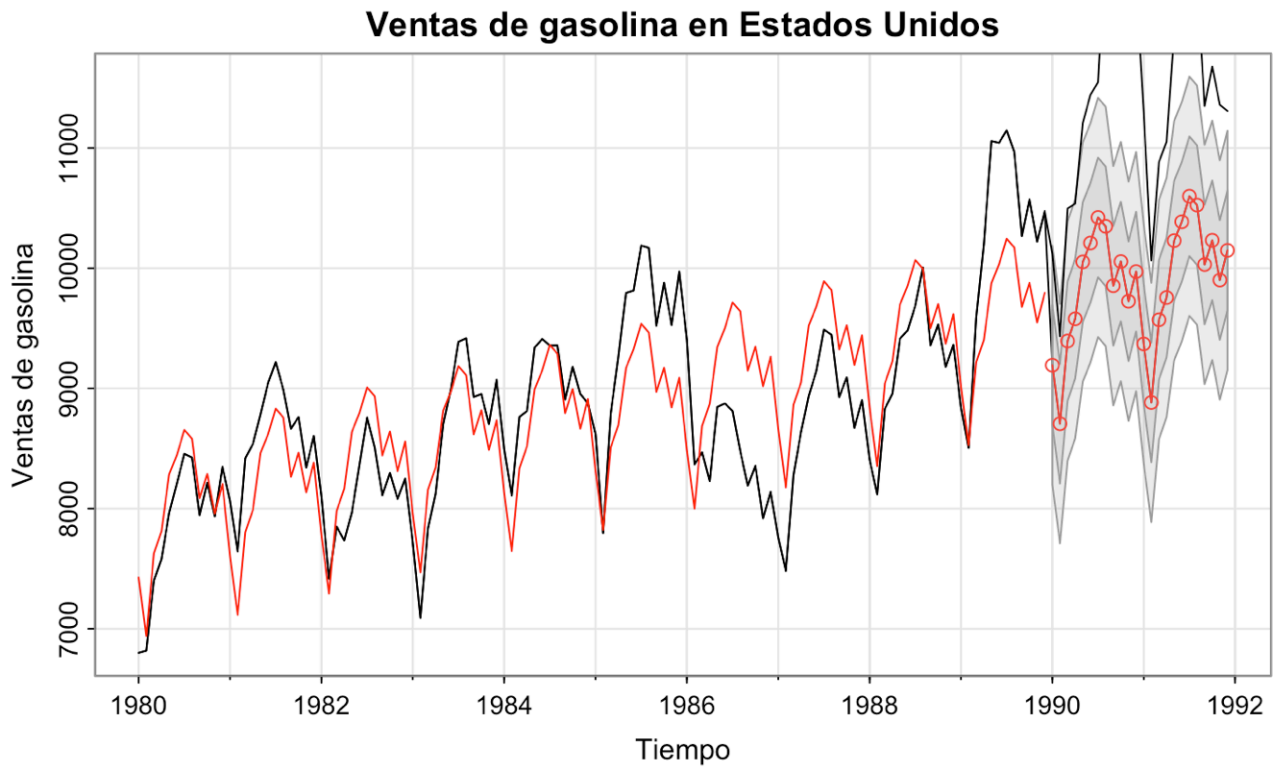

# Componente estacional estocástico: Modelos SARMA

# Componente estacional estocástico

Sea $y_t$ una serie de tiempo que presenta un patrón estacional estocástico. En este caso, la dependencia serial no ocurre en todos los retardos, sino en aquellos que son múltiplos de $s$. Por ejemplo:

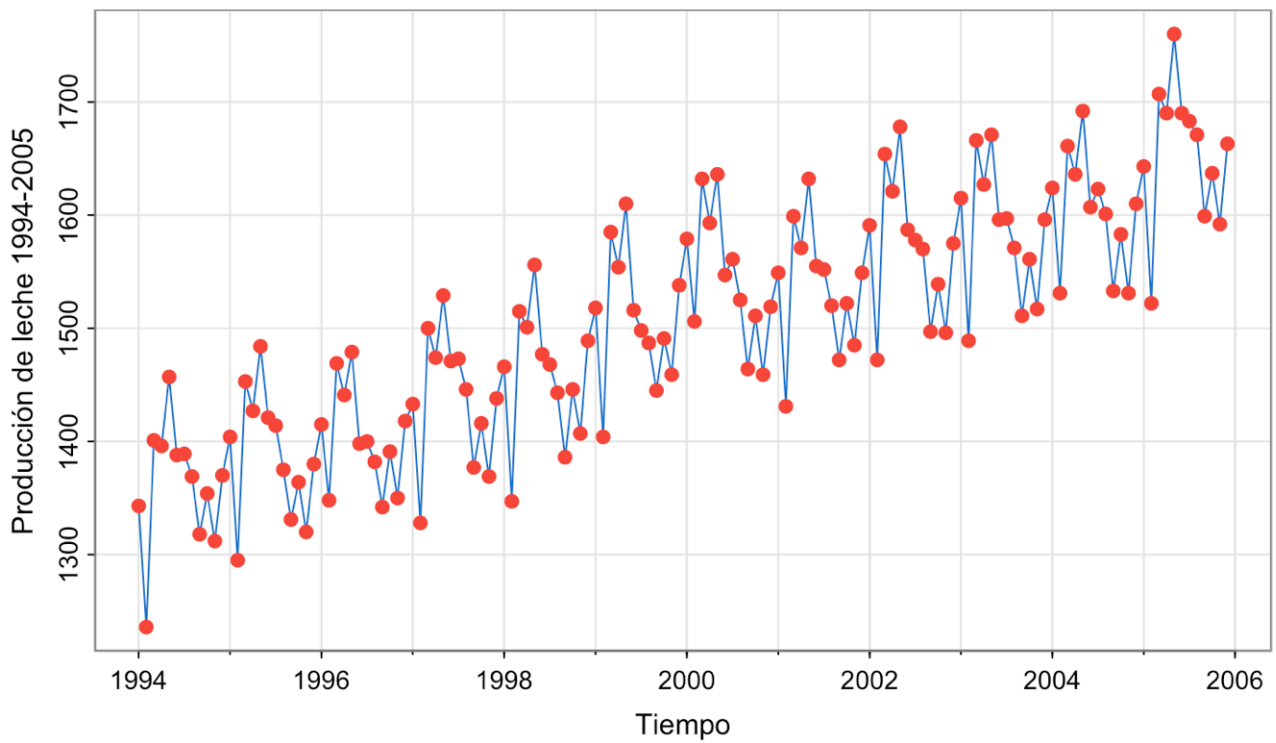


En el caso de la producción de leche en los Estados Unidos (datos mensuales de enero 1994 a diciembre 2005), la dependencia serial ocurre en cada trimestre ($s = 4$). ¿Cómo incorporamos esta estructura en el modelo?

# Modelo $MA(Q)_s$

Una serie de tiempo, $y_t$ sigue un proceso MA estacional (SMA) de orden $Q, s$ o $MA(Q)_s$ si:

$$
\begin{aligned}
y_t &= \varepsilon_t + \Theta_1 \varepsilon_{t-s} + \Theta_2 \varepsilon_{t-2s} + \cdots + \Theta_Q \varepsilon_{t-Qs}; \\
\varepsilon_t &\sim iid(0, \sigma^2)
\end{aligned}
$$

# Modelo $MA(1)_{12}$ (1/4)

Por ejemplo, sean $Q = 1$ y $s = 12$. Entonces:

$$y_t = \varepsilon_t + \Theta_1 \varepsilon_{t-12}$$

En este caso, se puede demostrar que:

$$\begin{aligned} \mu &= \mathbb{E}(y_t) \\ &= 0 \end{aligned}$$

# Modelo $MA(1)_{12}$ (2/4)

Además:

$$\gamma_k = \begin{cases} (1+\Theta_1^2)\sigma^2 & \text{si } k = 0 \\ \Theta_1 \sigma^2 & \text{si } k = 12 \\ 0 & \text{de otra forma} \end{cases} \qquad \rho_k = \begin{cases} 1 & \text{si } k = 0 \\ \frac{\Theta_1}{1+\Theta_1^2} & \text{si } k = 12 \\ 0 & \text{de otra forma} \end{cases}$$

Entonces, un proceso $\boldsymbol{MA}(1)_{12}$ es estacionario.

# Modelo $MA(1)_{12}$ (3/4)

Los siguientes datos simulan un proceso $\boldsymbol{MA}(1)_{12}$:

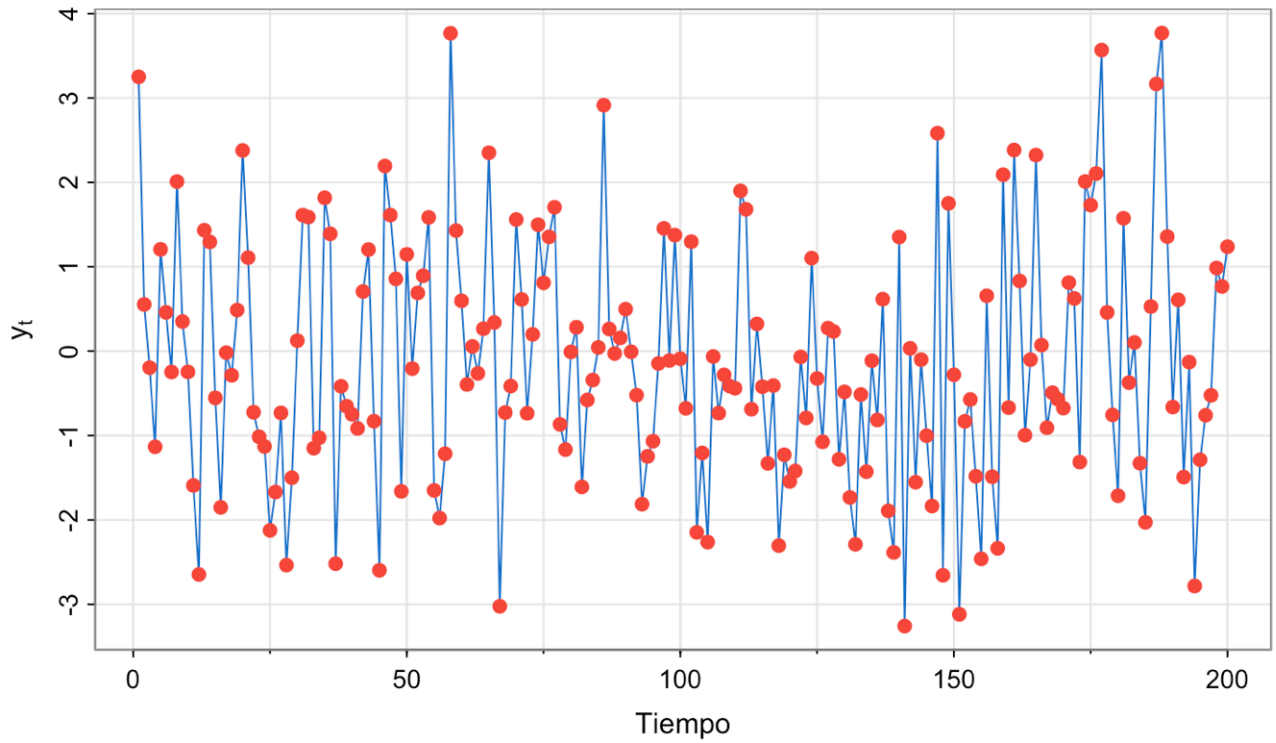


Nota que este proceso es equivalente a un $\boldsymbol{MA}(12)$ con $\theta_1 = \theta_2 = \cdots = \theta_11 = 0$.

# Modelo $MA(1)_{12}$ (4/4)

Para este proceso tenemos:

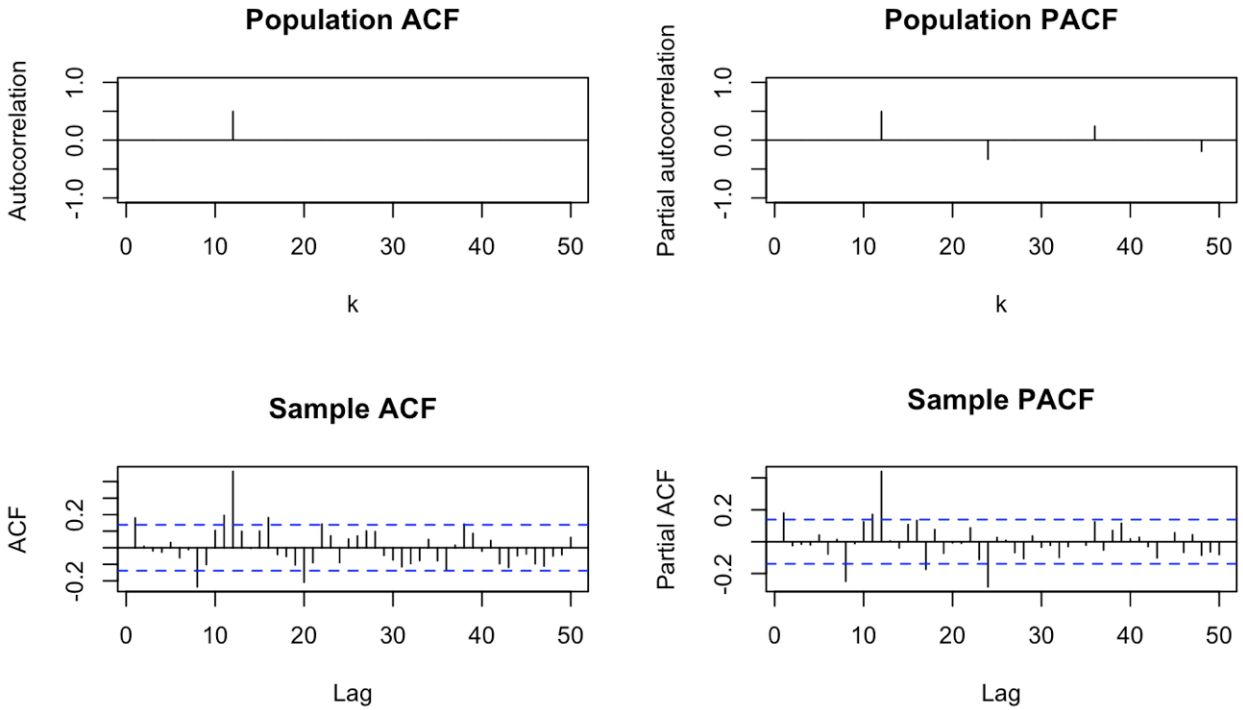

# Modelo $MA(2)_{12}$ (1/2)

Ahora, sean $Q = 2$ y $s = 12$. Entonces:

$$y_t = \varepsilon_t + \Theta_1 \varepsilon_{t-12} + \Theta_2 \varepsilon_{t-24}$$

Se puede demostrar que:

$$\begin{aligned} \mu &= \mathbb{E}(y_t) \\ &= 0 \end{aligned}$$

# Modelo $MA(2)_{12}$ (2/2)

Además:

$$\gamma_k = \begin{cases} (1+\Theta_1^2+\Theta_2^2)\sigma^2 & \text{si } k=0 \\ (\Theta_1+\Theta_1\Theta_2)\sigma^2 & \text{si } k=12 \\ \Theta_2\sigma^2 & \text{si } k=24 \\ 0 & \text{de otra forma} \end{cases} \qquad \rho_k = \begin{cases} 1 & \text{si } k=0 \\ \frac{\Theta_1+\Theta_1\Theta_2}{1+\Theta_1^2+\Theta_2^2} & \text{si } k=12 \\ \frac{\Theta_2}{1+\Theta_1^2+\Theta_2^2} & \text{si } k=24 \\ 0 & \text{de otra forma} \end{cases}$$

Nota que este proceso es equivalente a un $MA(24)$ con $\theta_1 = \theta_2 = \cdots = \theta_{11} = \theta_{13}, \theta_{14}, \ldots, \theta_{23} = 0$.

# Modelo $AR(P)_s$

Una serie de tiempo, $y_t$ sigue un proceso AR estacional (SAR) de orden $P$, $s$ o $AR(P)_s$ si:

$$
\begin{aligned}
y_t &= \Phi_1 y_{t-s} + \Phi_2 y_{t-2s} + \cdots + \Phi_P y_{t-Ps} + \varepsilon_t; \\
\varepsilon_t &\sim iid(0, \sigma^2)
\end{aligned}
$$

# Modelo $AR(1)_{12}$ (1/4)

Por ejemplo, sea $\boldsymbol{P} = 1$ y $s = 12$. Entonces:

$$y_t = \Phi_1 y_{t-s} + \varepsilon_t; \quad |\Phi_1| < 1$$

En este caso, se puede demostrar que:

$$\begin{aligned} \mu &= \mathbb{E}(y_t) \\ &= 0 \end{aligned}$$

# Modelo $AR(1)_{12}$ (2/4)

Además:

$$\gamma_0 = \frac{\sigma^2}{1 - \Phi_1^2}$$

y:

$$\rho_k = \begin{cases} \Phi_1^{k/12} & \text{si } k = 0, 12, 24, \ldots \\ 0 & \text{de otra forma} \end{cases}$$

# Modelo $AR(1)_{12}$ (3/4)

Los siguientes datos simulan un proceso $\boldsymbol{AR}(1)_{12}$:

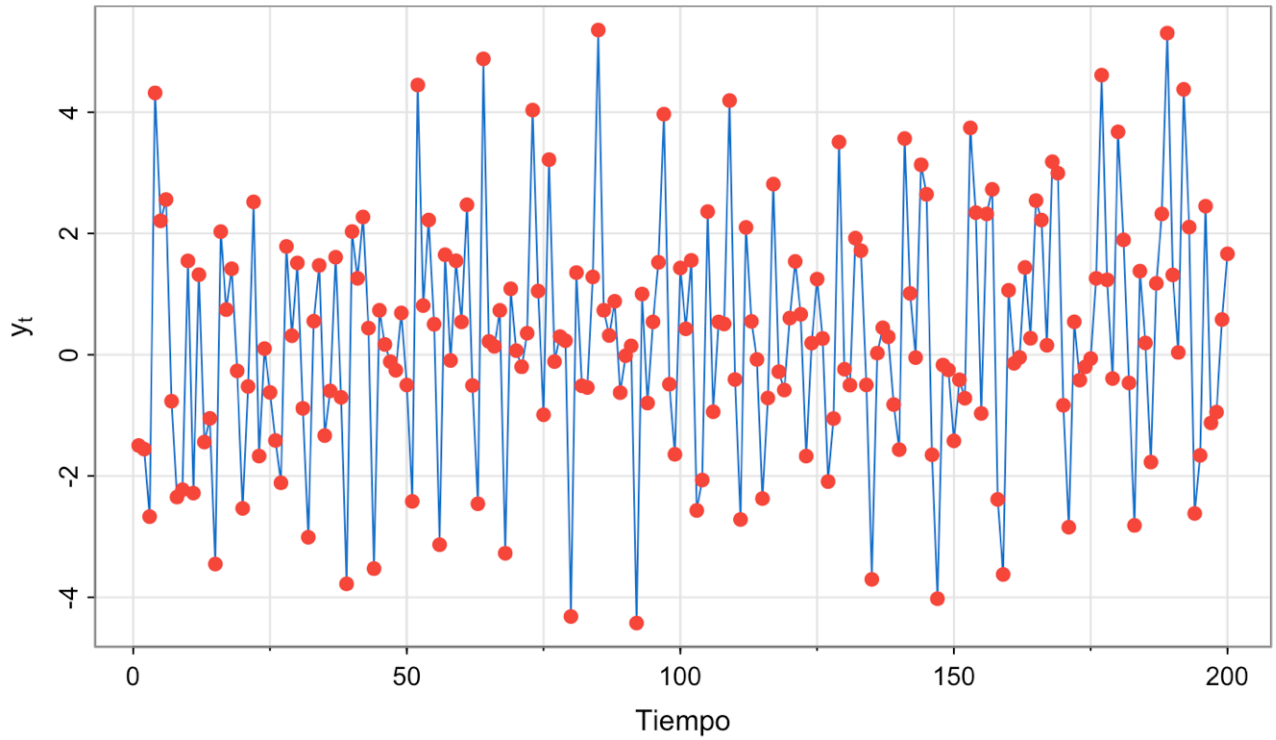


Nota que este proceso es equivalente a un $\boldsymbol{AR}(12)$ con $\phi_1 = \phi_2 = \cdots = \phi_1 1 = 0$.

# Modelo $AR(1)_{12}$ (4/4)

Para este proceso tenemos:

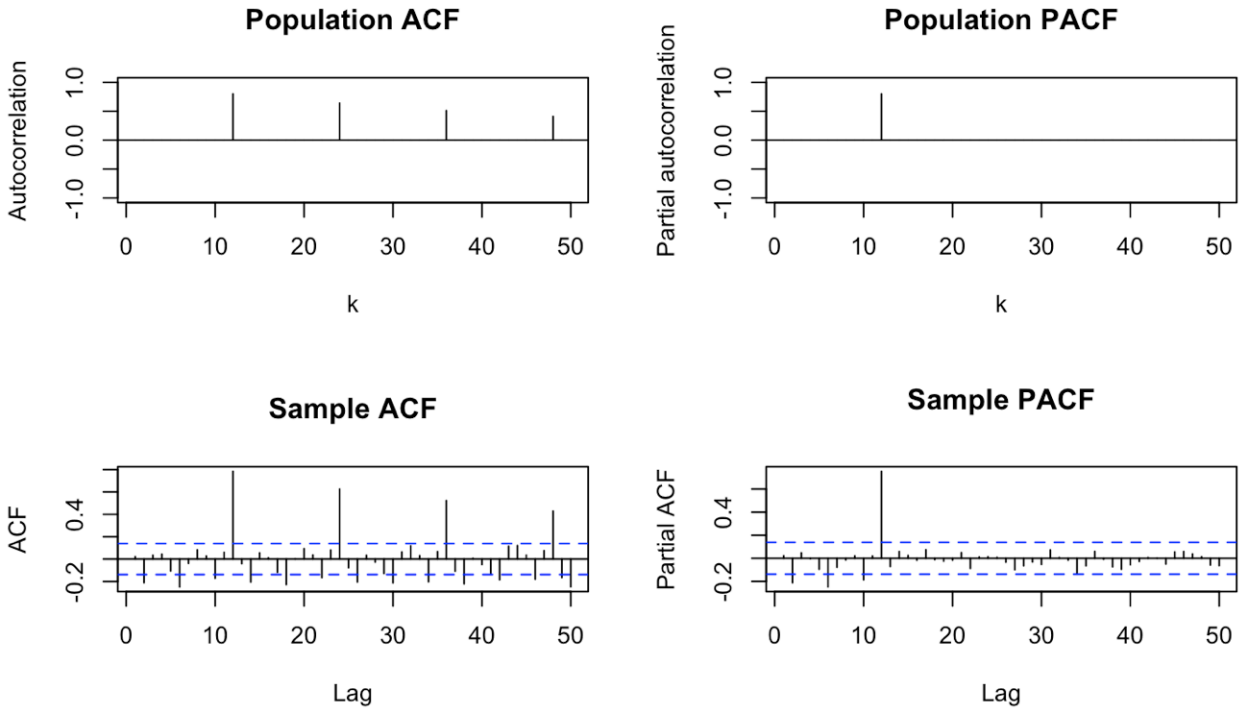

# Modelo $AR(2)_{12}$

Para un proceso $AR(2)_{12}$ se pede demostrar que:

- La función de autocorrelación decrece exponencialmente u oscilatoriamente en los retardos: $k = 12, 24, 36, 48, \ldots$
- La función de autocorrelación parcial es diferente de cero en los retardos $k = 12$ y $k = 24$. Es cero en todos los demás valores de $k$.
- Un proceso $AR(2)_{12}$ es equivalente a un $AR(24)$ con $\phi_1 = \phi_2 = \cdots = \phi_{11} = \phi_{13}, \phi_{14}, \ldots, \phi_{23} = 0$.

# Modelo $ARMA(P,Q)_s$ (1/2)

Una serie de tiempo, $y_t$ sigue un proceso ARMA estacional (SARMA) de orden $P, Q, s$ o $ARMA(P,Q)_s$ si:

$$y_t = \Phi_1 y_{t-s} + \Phi_2 y_{t-2s} + \cdots + \Phi_P y_{t-Ps} + \varepsilon_t + \Theta_1 \varepsilon_{t-s} + \Theta_2 \varepsilon_{t-2s} + \cdots + \Theta_Q \varepsilon_{t-Qs};$$
$$\varepsilon_t \sim iid(0, \sigma^2)$$

# Modelo $ARMA(P, Q)_s$ (2/2)

Un proceso $\boldsymbol{ARMA(P, Q)_s}$:

- Es equivalente a un $\boldsymbol{ARMA(p, q)}$ con autocorrelaciones diferentes de cero en los retardos $k = s, 2s, 3s, \ldots$.
- Es estacionario si y solo si las raíces del polinomio $\boldsymbol{\Phi_P(L^s)} = 0$ se encuentran *fuera del círculo unitario*.
- Es invertible si y solo si las raíces del polinomio $\boldsymbol{\Theta_Q(L^s)} = 0$ se encuentran *fuera del círculo unitario*.

# Modelos SARMA Multiplicativos

# Modelos SARMA Multiplicativos

Un proceso con componente estacional multiplicativo implica, como su nombre lo indica, multiplicar un proceso $ARMA(p, q)$ por un proceso $SARMA(P, Q)_s$.

# $MA(1) \times MA(1)_{12}$ (1/4)

Considera un proceso $MA(1)$:

$$\begin{aligned} y_t &= \varepsilon_t + \theta_1 \varepsilon_{t-1} \\ &= (1 + \theta_1 L)\varepsilon_t \end{aligned}$$

Y considera un proceso $MA(1)_{12}$:

$$\begin{aligned} y_t &= \varepsilon_t + \Theta_1 \varepsilon_{t-s} \\ &= (1 + \Theta_1 L^{12})\varepsilon_t \end{aligned}$$

# $MA(1) \times MA(1)_{12}$ (2/4)

Entonces, un proceso $MA(1) \times MA(1)_{12}$:

$$\begin{aligned} y_t &= (1 + \theta_1 L)(1 + \Theta_1 L^{12})\varepsilon_t \\ &= (1 + \theta_1 L + \Theta_1 L^{12} + \theta_1 \Theta_1 L^{13})\varepsilon_t \end{aligned}$$

O, de forma equivalente:

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13}$$

# $MA(1) \times MA(1)_{12}$ (3/4)

Para este proceso, se puede demostrar que:

$$\mathbb{E}(y_t) = 0$$

Y que:

$$\rho_1 = \frac{\theta_1}{1+\theta_1^2} \qquad \rho_{11} = \frac{\theta_1\Theta_1}{(1+\theta_1^2)(1+\Theta_1^2)}$$
$$\rho_{12} = \frac{\Theta_1}{1+\Theta_1^2} \qquad \rho_{13} = \frac{\theta_1\Theta_1}{(1+\theta_1^2)(1+\Theta_1^2)}$$

# $MA(1) \times MA(1)_{12}$ (4/4)

Entonces, un proceso $MA(1) \times MA(1)_{12}$:

- Tiene una FAC que es diferente de cero para los retardos $k = 1$ y $k = 12$.
- Tiene una FAC que es diferente de cero para los retardos $k = 11$ y $k = 13$.
- Es matemáticamente equivalente a un $MA(13)$ con parámetros: $\theta_1 = \theta_1, \theta_2 = \theta_2 = \cdots = \theta_{11} = 0$ y $\theta_{13} = \Theta_1$.

# $MA(1) \times AR(1)_{12}$ (1/3)

Considera un proceso $MA(1)$:

$$\begin{aligned} y_t &= \varepsilon_t + \theta_1 \varepsilon_{t-1} \\ &= (1 + \theta_1 L)\varepsilon_t \end{aligned}$$

Y considera un proceso $AR(1)_{12}$:

$$\begin{aligned} y_t &= \Phi_1 y_{t-12} + \varepsilon_t \\ (1 - \Phi_1 L^{12}) y_t &= \varepsilon_t \end{aligned}$$

# $MA(1) \times AR(1)_{12}$ (2/3)

Entonces, un proceso $MA(1) \times AR(1)_{12}$:

$$(1 - \Phi_1 L^{12})y_t = (1 + \theta_1 L)\varepsilon_t$$

O, de forma equivalente:

$$y_t = \Phi_1 y_{t-12} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

# $MA(1) \times AR(1)_{12}$ (3/3)

Entonces, un proceso $MA(1) \times AR(1)_{12}$:

- Tiene una FAC que es del tipo AR en los retardos $k = 12, 24, 26 \ldots$.
- Tiene una FAC que es del tipo MA en el retardo $k = 1$ y en $k = 11, 13, 25, \ldots$.
- Es matemáticamente equivalente a un $ARMA(12, 1)$ con parámetros: $\phi_1 = \phi_2 = \cdots = \phi_{11} = 0$, $\phi_{12} = \Phi_1$ y $\theta_1 = \theta_1$.

# FAC y FACP

Para los procesos multiplicativos que hemos visto tenemos:

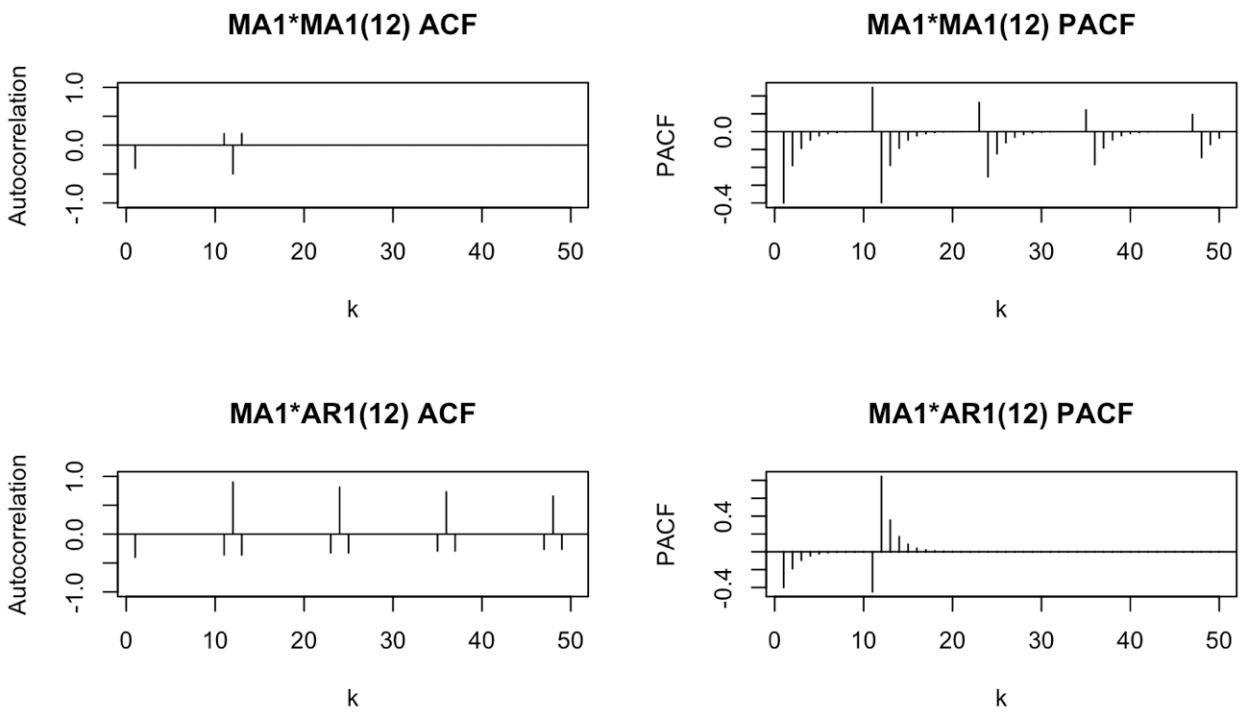

# $ARMA(p,q) \times ARMA(P,Q)_s$

El proceso $ARMA(p,q) \times ARMA(P,Q)_s$ es el más general de los modelos multiplicativos. Se puede demostrar que:

- Es matemáticamente equivalente a un proceso ARMA con los coeficientes de su parte AR caracterizados por $\mathbf{\Phi}^*(L) = \mathbf{\Phi}(L)\mathbf{\Phi}_P(L^s)$ y los coeficientes de su parte MA caracterizados por $\mathbf{\Theta}^*(L) = \mathbf{\Theta}(L)\mathbf{\Theta}_Q(L^s)$.

- Debido a esta equivalencia, podemos utilizar los mismos métodos de especificación, ajuste, diagnósticos, etc., de un modelo ARMA.

# $ARMA(p,q) \times ARMA(P,Q)_s$: Ejemplo (1/3)

Considera los siguientes datos sobre el uso de transporte (autobús y tren ligero) en Denver y Colorado. Los datos van desde agosto 2000 hasta marzo 2006. (Los datos se encuentran en escala logarítmica).

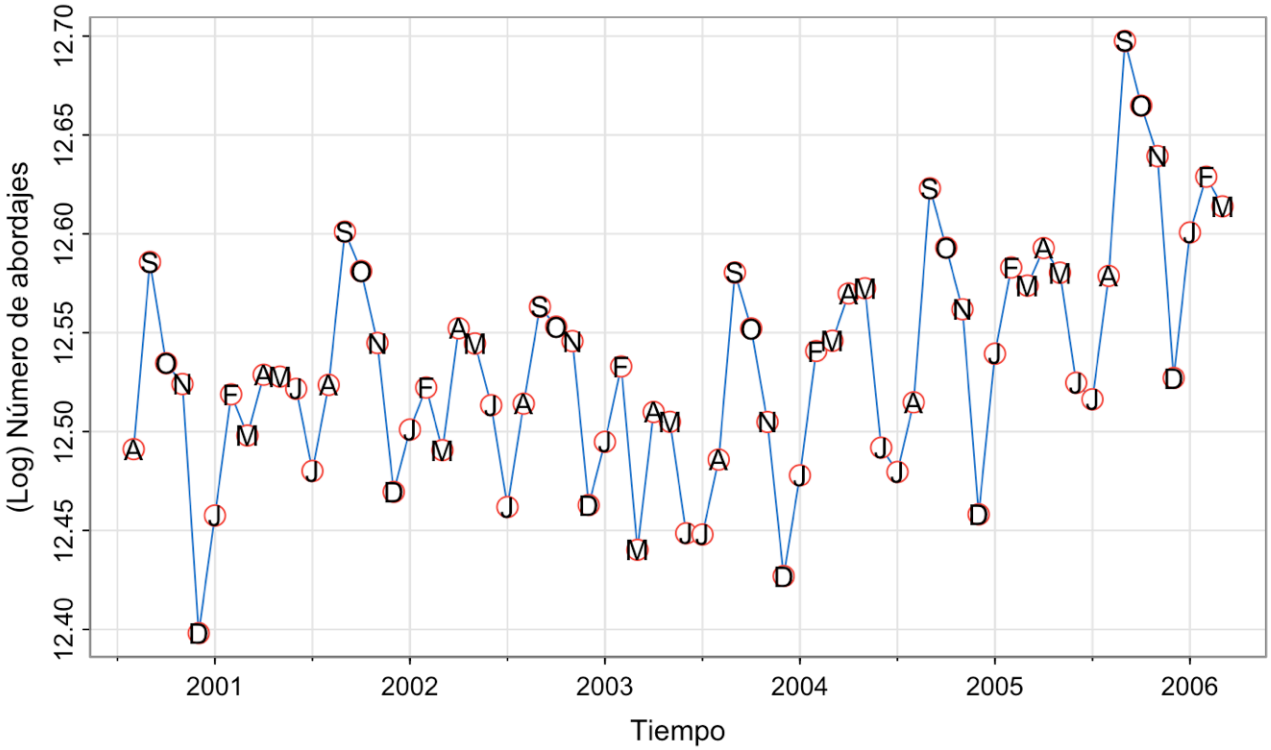

# $ARMA(p,q) \times ARMA(P,Q)_s$: Ejemplo (2/3)

La siguiente figura presenta la FAC y la FACP. Estos sugieren un modelo $ARMA(0,3)xARMA(1,0)_{12}$:

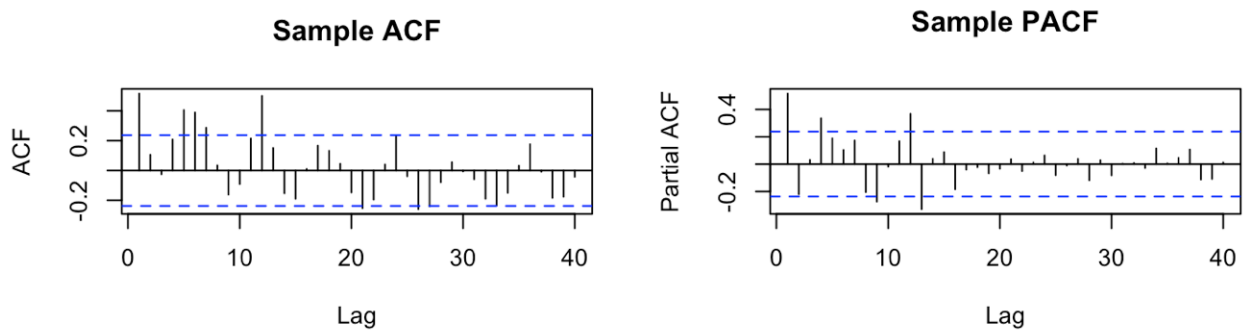

# $ARMA(p,q) \times ARMA(P,Q)_s$: Ejemplo (3/3)

Utilizamos el periodo agosto 2000 a julio 2005 para ajustar el modelo y utilizamos el resto de los datos para analizar qué tan bueno es el pronóstico:

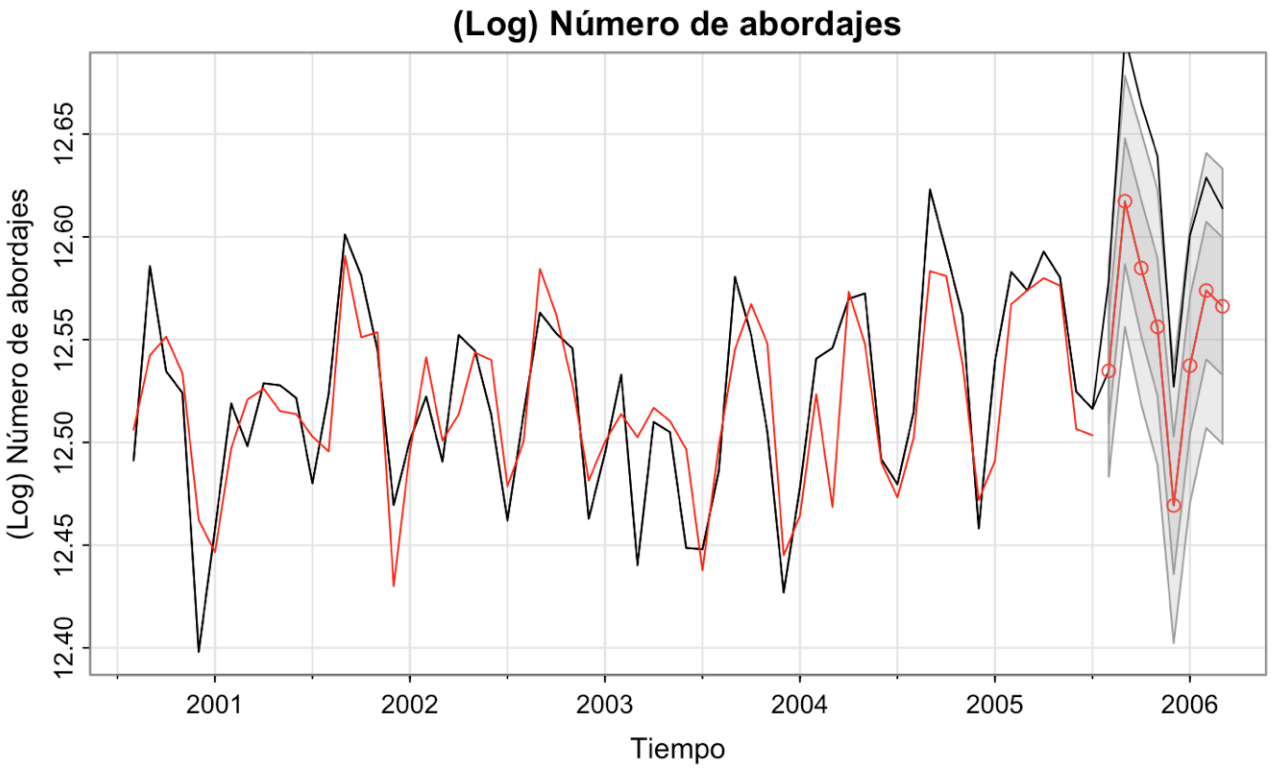

# Modelos SARIMA

# Diferencias

Recordemos que las primeras diferencias de una serie de tiempo, $y_t$ , se calculan como:

$$\begin{aligned}\Delta y_t &= y_t - y_{t-1} \\ &= (1 - L)y_t\end{aligned}$$

Podemos diferenciar la serie de tiempo $d$ veces:

$$\Delta^d y_t = (1 - L^d)y_t$$

# Diferencias: Ejemplo

Considera el proceso no estacionario:

$$
\begin{aligned}
y_t &= s_t + \varepsilon_t \\
s_t &= s_{t-12} + u_t \\
u_t &\sim iid(0, \sigma_u^2)
\end{aligned}
$$

Si tomamos primeras diferencias obtenemos:

$$\Delta y_t = (s_{t-12} - s_{t-13}) + (u_t - u_{t-1}) + (\varepsilon_t - \varepsilon_{t-1})$$

Sin embargo, este proceso sigue siendo *no estacionario*. ¿Por qué?

# Diferencias estacionales

Definimos el operador de diferencias estacionales, $\Delta_s$:

$$\Delta_s y_t = y_t - y_{t-s} \qquad = (1 - L^s) y_t$$

Recuerda: si tenemos datos mensuales, $s = 12$, si tenemos datos trimestrales, $s = 4$, etc.

# Diferencias estacionales: Ejemplo (1/2)

Considera el proceso no estacionario:

$$
\begin{aligned}
y_t &= s_t + \varepsilon_t \\
s_t &= s_{t-12} + u_t \\
u_t &\sim iid(0, \sigma_u^2)
\end{aligned}
$$

Si tomamos *primeras diferencias estacionales* obtenemos:

$$\Delta_{12} y_t = u_t + \varepsilon_t - \varepsilon_{t-12}$$

Se puede mostrar que este proceso tiene la misma FAC que un $MA(1)_{12}$.

# Diferencias estacionales: Ejemplo (2/2)

Datos sobre la producción de leche en Estados Unidos:

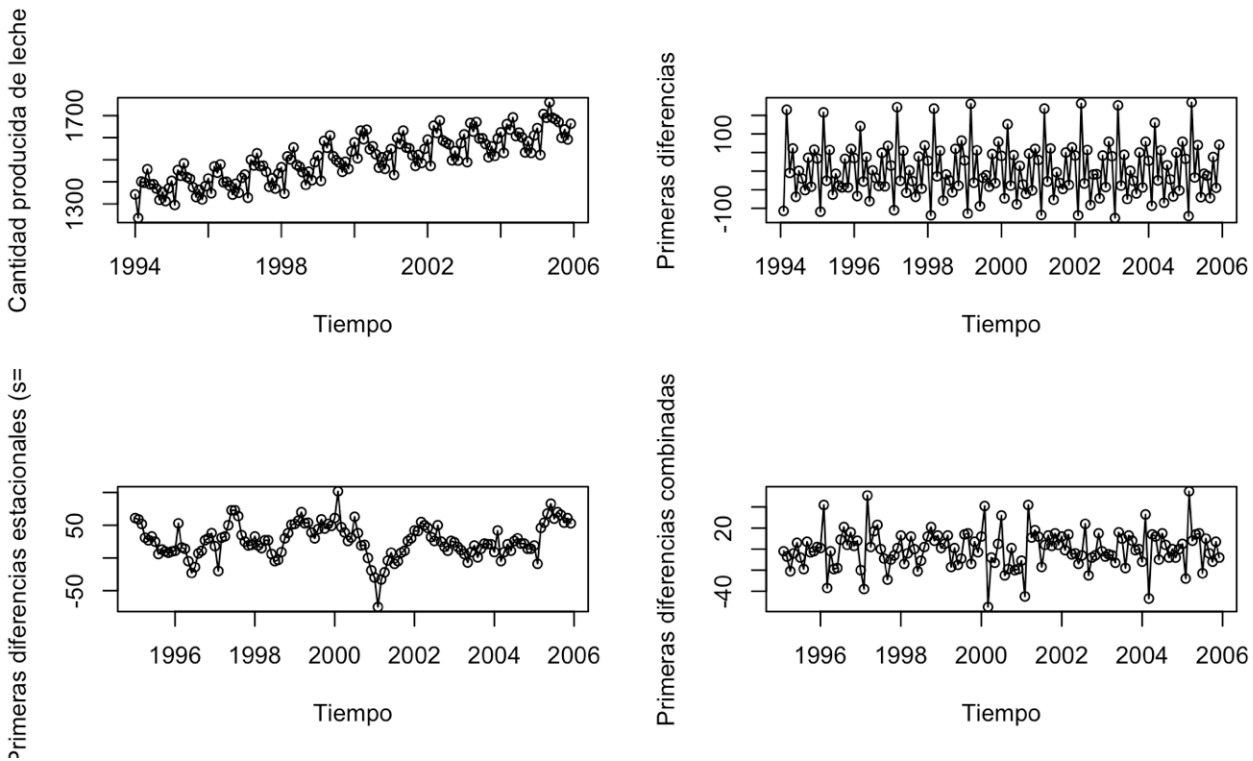

# Modelos SARIMA (1/2)

Entonces, podemos extender los modelos SARMA para incorporar las dos fuentes de no estacionariedad.

Supongamos que $\varepsilon_t \sim iid(0, \sigma^2)$. Un modelo **ARIMA con componente estacional multiplicativo** (SARIMA), o $ARIMA(p, d, q) \times ARIMA(P, D, Q)_s$:

$$\mathbf{\Phi}(L)\mathbf{\Phi}_P(L^s)\Delta^d\Delta_s^D y_t = \mathbf{\Theta}(L)\mathbf{\Theta}_Q(L^s)\varepsilon_t$$

# Modelos SARIMA (2/2)

Se puede demostrar que:

$$y_t \sim ARIMA(p, d, q) \times ARIMA(P, D, Q)_s$$

si y solo si:

$$\Delta^d \Delta_s^D y_t \sim ARMA(p, q) \times ARMA(P, Q)_s$$

# Modelos SARIMA: Ejemplo (1/3)

Funciones de autocorrelación y autocorrelación parcial para las primeras diferencias combinadas sobre la producción de leche en Estados Unidos:

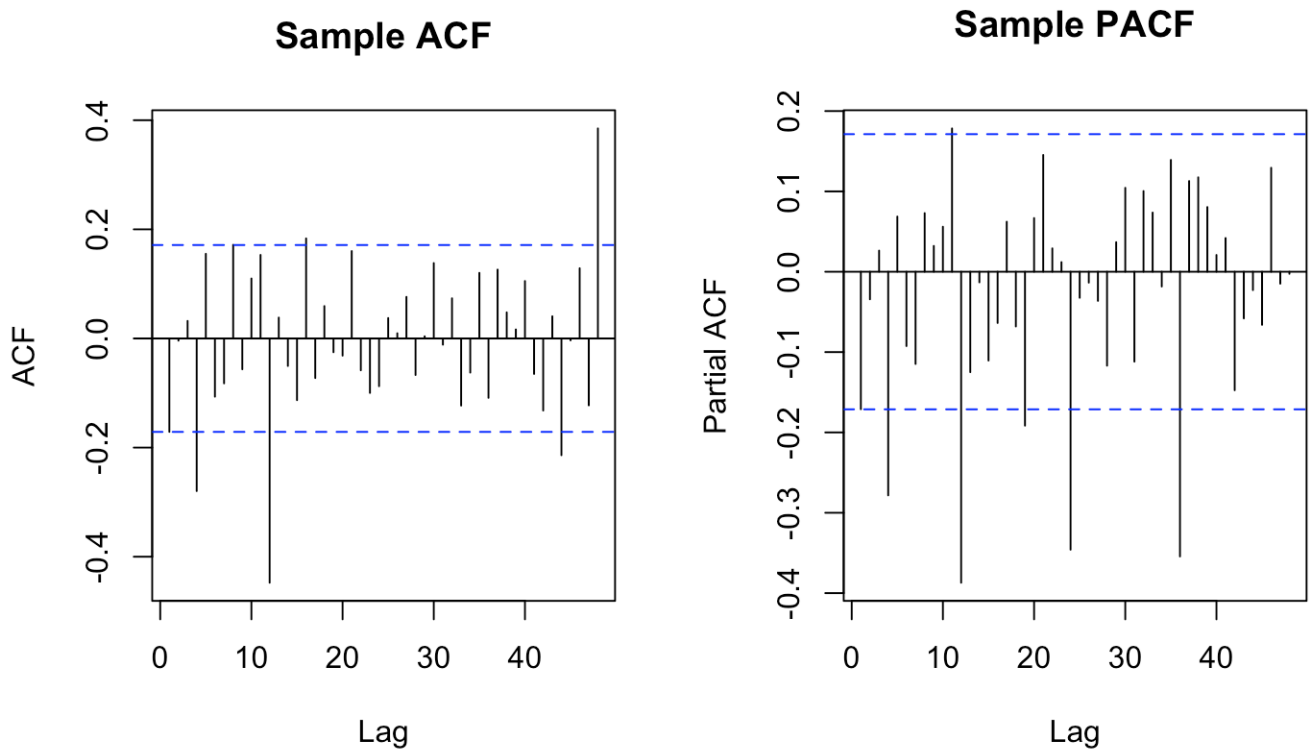

# Modelos SARIMA: Ejemplo (2/3)

De las FAC y FACP anteriores, los siguientes modelos podrían resultar adecuados:

- $ARIMA(0,1,0) \times ARIMA(0,1,1)_{12}$
- $ARIMA(0,1,0) \times ARIMA(3,1,0)_{12}$

¿Por qué?

# Modelos SARIMA: Ejemplo (3/3)
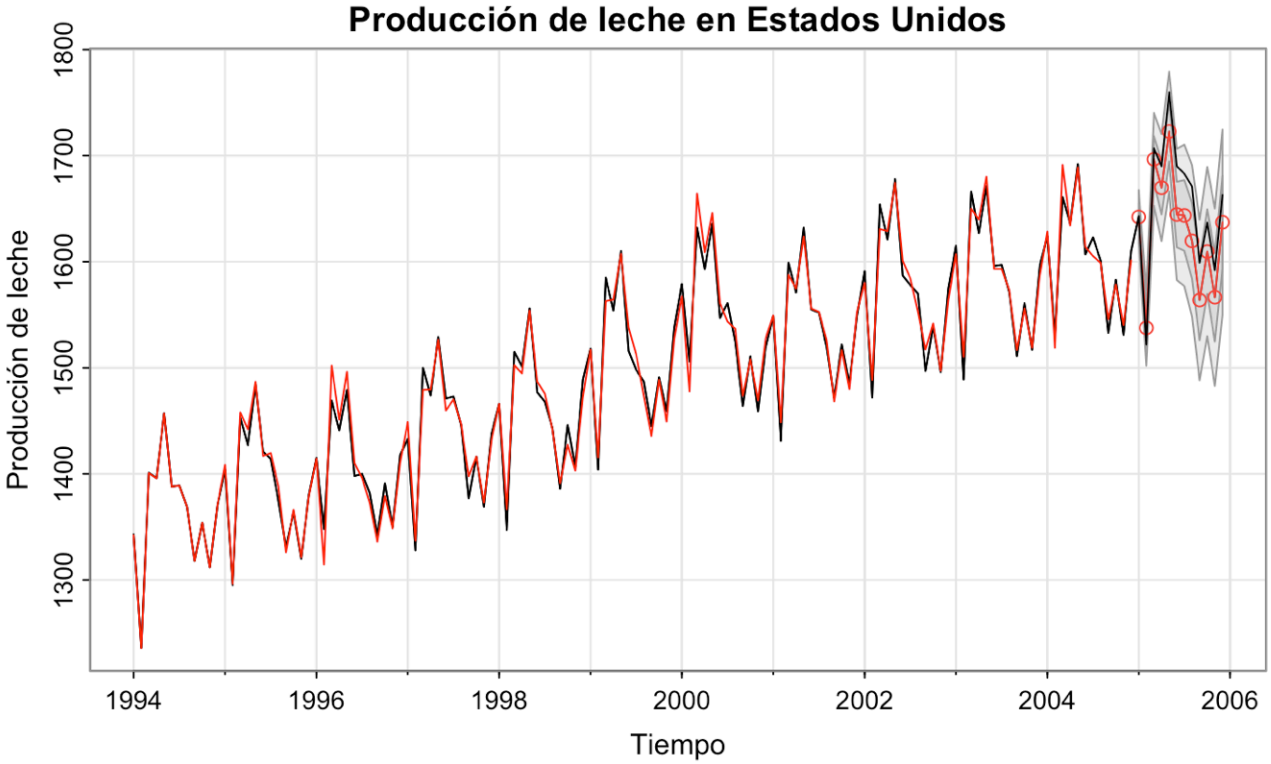
Utilizamos el periodo enero 1994 a diciembre 2004 para ajustar el modelo y utilizamos el resto para analizar qué tan bueno es el pronóstico: